모델링 결과서

접수번호	A263031
팀명	LazyScientist
공모전 중복 참여여부	이어드림스쿨 5 기 스타트업 연계 프로젝트 바이오 분야(중소벤처기업진흥공단, 2 등 우수상, 2025.12, 교육 과정(이어드림스쿨 5 기) 내 대회) 난임 환자 대상 임신 성공 여부 예측 AI 해커톤(㈜데이콘, 2 등, 2026.04, 교육 과정(오즈코딩스쿨 헬스케어AI 3 기) 내 대회)
주요 활용 라이브러리	PyTorch 2.14 · segmentation-models-pytorch 0.5.0 · albumentations 2.0.8 · scikit-image 0.26.0 · scikit-learn 1.9.1 · NumPy 2.5.3 · SciPy 1.18.1 · Pillow 12.3.0

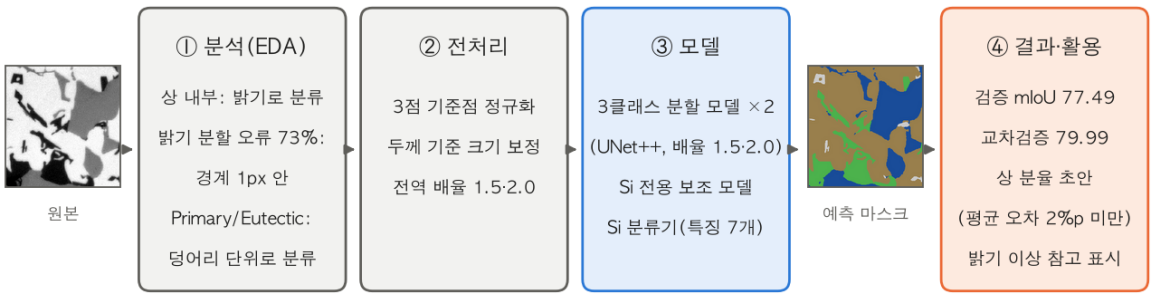
배경 및 아이디어 소개(요약)

○ 아이디어 제안 배경

- 합금 개발에서는 네 미세조직 클래스의 area fraction(면적 비율)과 형태를 조성별로 비교한다.
- 조성을 바꿀 때마다 현미경 사진의 미세조직을 손으로 나눠 세는 일은 시간이 많이 든다.
- 정답 마스크 90 장을 원본과 대조하니 상 내부는 밝기로 분류되고 오류는 경계에 몰렸다.
- 정답은 밝기가 겹치는 두 Si를 connected component(이어진 픽셀 영역) 단위로 나눴다.
- 그래서 3 클래스 분할과 Si 덩어리 단위 분류를 나눠 검증 mIoU 77.49 를 얻었다.

○ 파급효과

- 사진마다 네 상의 area fraction을 자동으로 만든다(검증 20 장 평균 절대 오차 2%p 미만).
- 밝기 정규화는 정답 없이 계산하고 크기 보정은 폭별 고정 계수라, 새 이미지에 그대로 쓴다.
- 같은 합금계의 탄성률 연구가 상 분율 검증에 쓰는 OM 분할을 자동으로 하므로, XRD 기반 탄성률 예측에 분율·형태 지표를 더해 보는 후속 연구로 이어질 수 있다.



고탄성 알루미늄 합금 이미지 상 분할 인공지능 모델
분석·모델링 결과서

① 분석(EDA) 개요

1-1. 분석 핵심 내용

○ 밝기와 정답이 어긋나는 픽셀의 90.7%(이미지별 중앙값)가 경계 2px 띠 안에 있어, 3 상 분할은 경계를 복원하는 분할 모델에 맡김

○ Primary Si와 Eutectic Si는 connected component(서로 이어진 픽셀 영역) 단위로 나뉘어 그 단위로 분류함

○ 상 내부는 밝기로 구분되나 경계는 구분되지 않음

- 같은 회색값인데 정답 클래스가 다른 픽셀(그 회색값에서 가장 흔한 클래스가 아닌 픽셀)은 밝기만으로는 맞힐 수 없음. 이런 픽셀은 두 Si를 합친 3 클래스 기준으로 이미지 한 장에 보통 9.5%이고(학습·검증 90 장의 이미지별 비율을 크기순으로 늘어놓은 가운데 값), 상 경계 2px 띠(이미지의 약 5 분의 2)를 빼고 다시 구하면 1.2%로 줄어듦. 줄어드는 것은 90 장 모두 같음

○ 점수를 잃는 곳도 경계임

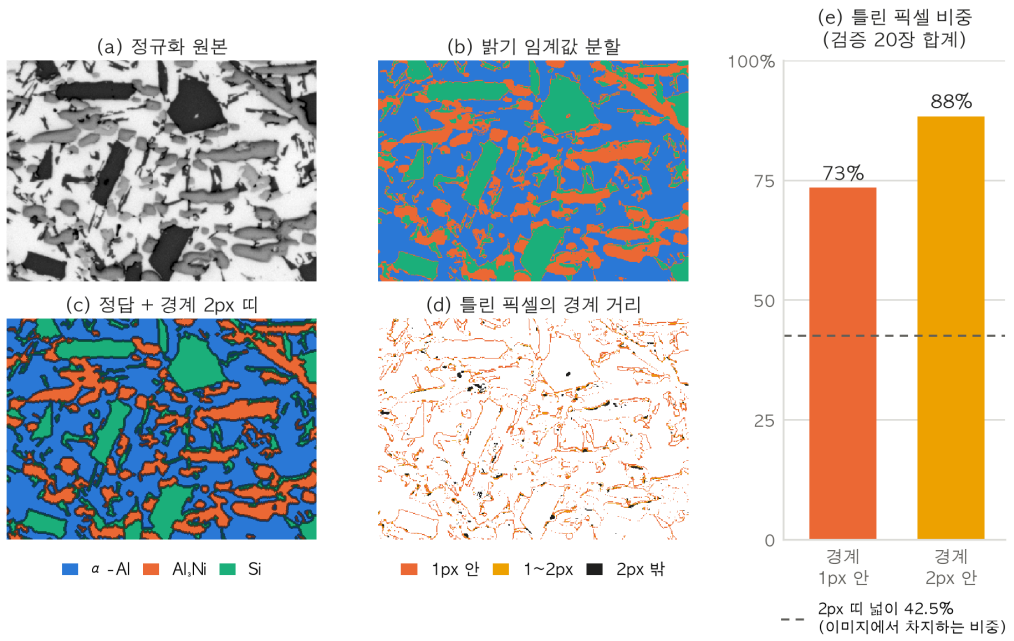


그림 1. 경계 2px 띠와 밝기 임계값 분할이 틀리는 자리.

검증 20 장 가운데 대표 이미지(A40_step3_sample3)의 가운데 영역이다. (b) 정규화 뒤 이미지별 최적 임계값 분할, (c) 다른 상과 2px 이내인 정답 경계 띠(Primary/Eutectic 사이 제외), (d) 틀린 픽셀의 정답 경계까지 거리, (e) 20 장 합산 비중이다. 띠는 이미지의 42.5%인데 틀린 픽셀은 88%가 이 띠 안에, 73%가 1px 안에 있다.

- 3 점 기준점 정규화(이미지마다 어두운·중간·밝은 세 밝기 구간의 평균을 정해진 세 값에 맞추는 밝기 보정, ②-1) 뒤 이미지별 최적 밝기 임계값으로 나눠도 틀린 픽셀은 정답 경계에 몰림(그림 1). 그래서 **경계 복원을 분할 모델의 핵심 과제로** 봤고, 경계 2px를 손실 함수 계산에서 빼고 학습하면 교차검증 다섯 묶음(fold) 모두에서 4 클래스 mIoU가 떨어졌음(−2.63, 초기 비교·산식 확정 전 값)

○ Primary Si와 Eutectic Si는 connected component 단위로 구분됨

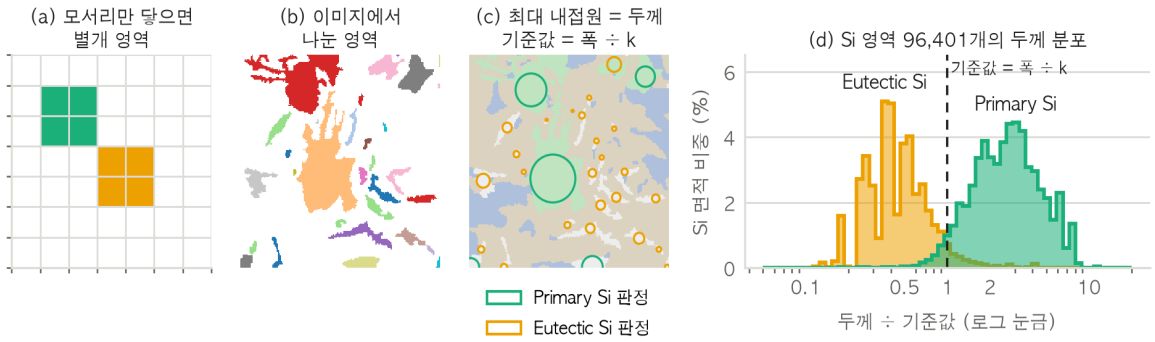


그림 2. connected component와 두께의 뜻.

(a) 같은 클래스 픽셀이 상하좌우로 변을 맞대면 한 영역이다(scikit-image[3]의 label, 4 방향 연결). (b) 정답 Si 마스크(A154_step2_sample3)를 영역마다 다른 색으로 칠했다. (c) 최대 내접원 지름이 기준값(이미지 폭 ÷ k)보다 크면 Primary Si다(두께 공식, ③-1 의 비교 기준선). (d) 90 장의 Si 영역 96,401 개를 두께 ÷ 기준값으로 늘어놓고 면적으로 가중했다.

- connected component(연결 성분)는 같은 클래스 픽셀이 상하좌우로 이어진 한 덩어리임(그림 2 (a)). 이 결과서는 Si 덩어리 하나를 Primary/Eutectic 판정의 단위로 씀
- Primary Si는 액상에서 먼저 정출한 Si, Eutectic Si는 α-Al과 함께 공정 반응으로 생긴 Si이며, 같은 합금계(Al-18Si-8Ni) 주조재의 광학현미경 사진에서 Primary Si는 별 모양(냉각 10 K/s)이나 다각형(50 K/s) 입자로, Eutectic Si는 조각 모양으로 관찰됨[2]. 정답의 두 Si를 한 Si로 합친 뒤 덩어리로 나누면 학습·검증 90 장의 덩어리 96,401 개 가운데 99.975%는 안에 한 종류의 Si만 들어 있음. 정답은 덩어리 단위로 Primary/Eutectic이 정해져 있다는 뜻이라 덩어리마다 하나로 판정하면 됨
- Si 덩어리의 형태·밝기 지표 16 종(크기·길이 8, 모양 비율 6, 밝기 2) 가운데 두께(최대 내접원 지름, SciPy[4]의 거리 변환으로 계산)가 가장 잘 구분했고(두께 하나로 나눈 오분류 4.82%, 같은 합금이 학습과 평가에 함께 들어가지 않게 나눈 5-fold 교차검증), 결정트리(scikit-learn[5])로 여러 지표를 조합해도 두께 하나보다 낫지 않았음

1-2. 분석 배경

○ 학습 70 장·검증 20 장·평가 10 장, 4 클래스이며 채점은 이미지별 4 클래스 mIoU임

○ 이미지마다 밝기와 크기가 달라, 밝기는 상대 위치를 맞추는 정규화로, 크기는 폭별 두께 기준값의 비로 맞춤

○ **데이터**

- 학습 70 장·검증 20 장·평가 10 장, 클래스는 α-Al·Al_3Ni·Primary Si·Eutectic Si 네 가지이며[6], Al-Si-Ni 주조 합금의 공개 연구[21]도 광학현미경 사진을 같은 네 클래스로 나눔. 학습 픽셀 비율은 α-Al 57.28 / Al_3Ni 26.31 / Primary Si 9.43 / Eutectic Si 6.98%임
- 채점은 이미지마다 네 클래스 IoU(겹친 면적 ÷ 합친 면적)를 평균한 mIoU이며, 주최 측 산식[1]은 정답·예측 한쪽에만 있거나 둘 다 없는 클래스를 IoU 0 으로 넣어 Primary Si가 없는 이미지(학습·검증 한 장씩)는 75 점을 넘지 못함

○ **이미지마다 절대 밝기는 다르지만 상의 밝기 순서는 같다**

상 내부 밝기(경계 2px 제외)의 이미지별 중앙값은 Si가 14~120 으로 Al_3Ni(105~184)와 겹쳐 공통 임계값은 쓸 수 없지만, Si < Al_3Ni < α-Al 순서는 학습 70 장 모두 같아 세 상의 상대 위치를 맞추는 정규화를 택했다(②-1).

○ **파일명 정보는 교차검증 분할과 점수 해석에 활용**

데이터에는 촬영 조건·조성 같은 메타정보가 없어, 파일명 A{합금ID}_step{n}_sample{m}의 합금 ID와 step은 교차검증 묶음과 점수 해석에만 썼다(모델 입력에는 쓰지 않음).

- 합금 ID는 A2~A224 의 77 개이며, ID가 커질수록 Al_3Ni가 늘고(r = 0.65) Primary Si가 줄어(r = −0.47) 조성 순서와 이어져 있을 수 있음. 메타정보가 없어 추정에 그침
- 같은 합금 ID를 가진 이미지 쌍 21 개(합금 17 개)는 Al_3Ni 분율 차이가 4.28%p로, 같은 이미지끼리만 빼고 무작위로 짝지은 쌍(8.36%p)의 절반 정도였음. 같은 합금 시편끼리 미세조직이 닮았다는 뜻이라, 같은 합금이 학습과 평가에 함께 들어가면 점수가 부풀려지므로 교차검증을 합금 그룹으로 나눴음(③-2). 다만 같은 합금 안에서도 클래스별 평균 차이가 2.67~4.28%p라 시야 한 장이 그 합금을 대표하는지는 따로 확인해야 함
- 평가 10 장은 학습과 합금이 겹치는 3 장, 검증과만 겹치는 1 장, 처음 보는 6 장이라 내부 검증 점수도 겹침 여부로 나눠 보고함(③-3)

○ **이미지 크기가 섞여 있다**

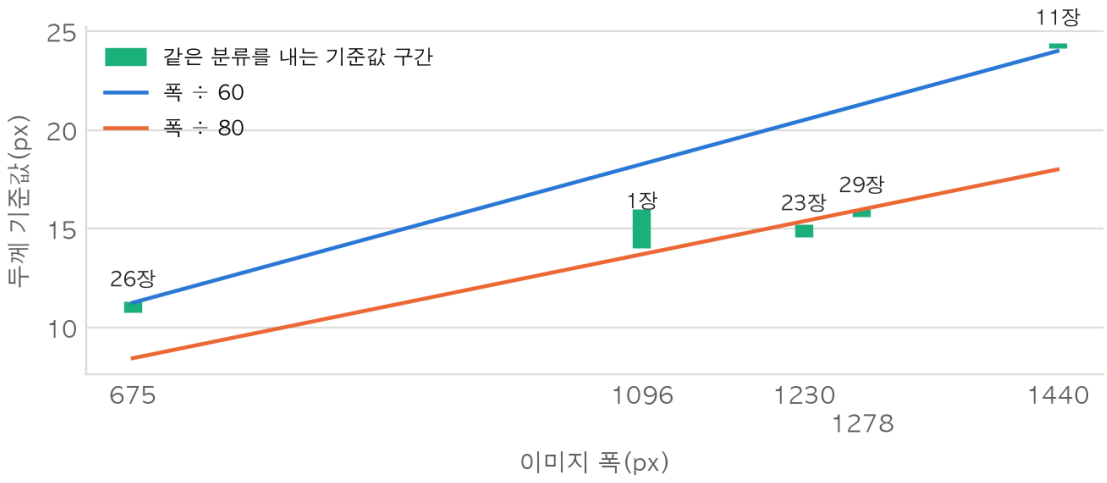


그림 3. 이미지 폭별로 정답 마스크에서 찾은 Primary/Eutectic 두께 기준값.

같은 분류를 내는 기준값 구간을 세로 막대로, 크기 그룹별 공식(폭 ÷ k, k는 60·80)을 직선으로 그렸다. 1096px은 검증 한 장뿐이라 구간이 넓다. 직선은 ③-1 의 비교 기준선인 두께 공식이며 1096·1230·1440px에서는 구간을 조금 벗어난다.

이미지 폭은 5 종(675·1096·1230·1278·1440px)이다. 정답에서 폭별로 찾은 Primary/Eutectic 두께 기준값은 675px 11.3px, 1440px 24.2px로 비가 2.14 배여서 폭의 비 2.13 배와 거의 같았고, 1096·1230·1278px 묶음은 폭 대비 기준값이 약 4 분의 3 이었다(1096px은 검증 한 장뿐, 그림 3). 이 비를 크기 그룹별 보정 계수로 쓰며(②-1), 기준값은 학습·검증 90 장 정답에서 찾았다(데이터 사용 범위는 ③-2). 촬영 정보가 없어 정답의 두께 기준값으로 크기 그룹 사이의 상대 크기를 맞춘 것은, 고분해능 투과전자현미경에서 알려진 격자 간격으로 배율을 교정하던 방식에서 온 발상이며 실제 광학 배율의 비인지는 확인하지 못했다.

1-3. 분석 방법 및 분석 내용

표 1. 분석 테마별 질문과 설계 결정

테마	질문	활용한 데이터	답과 설계 결정
밝기	이미지마다 밝기가 다른가	학습 70 장	다르다(Si 14~120) → 상대 위치 정규화
	기준점은 2 점인가 3 점인가	학습 70 장(임계값)·검증 20 장(비교)	3 점(양 끝만 맞추면 중간이 어긋남)
	이미지마다 Al_3Ni의 상대 밝기 위치 (Al_3Ni−Si)÷(α-Al−Si)가 흔들리나	학습·검증 90 장 상 내부 밝기	5~95 백분위 구간이 0.39~0.61 로 흩어짐(step과만 상관) → 광도 증강의 감마 범위(②-1)
경계	밝기만으로 어디까지 되나	검증 20 장	정규화 뒤 이미지마다 그 정답으로 고른 3 클래스 최적 임계값과 두께 공식으로도 4 클래스 71.8%
	오류가 경계에 몰리나		73%가 1px 안 → 모델의 일은 경계 복원
형태	Primary/Eutectic을 구분하는 변수는	90 장 Si connected component 96,401 개	두께가 가장 잘 구분(오분류 4.82%) → 비교 기준선. 제출은 두께를 포함한 특징 7 개의 Si 분류기(③-1)

※ 방식끼리 비교한 임계값은 학습 70 장으로 정하고(71.8%와 그림 1 은 이미지마다 그 정답으로 고른 임계값 기준), 방식끼리 비교한 점수는 학습에 쓰지 않은 검증 20 장에서 쟀다. 밝기 차이는 학습 70 장으로 확인했으며 검증 20 장도 같다(Si 4~101). 90 장 행은 정답의 분포를 본 것이다.

② 데이터 전처리

2-1. 전처리 방법

○ 밝기: 세 밝기 구간의 평균을 50·140·226 에 맞추는 3 점 기준점 정규화로 이미지마다 다른 밝기를 맞춤

○ 크기: 폭별 두께 기준값의 비로 크기 그룹 사이를 맞추고, 폭 2~6px Eutectic Si가 사라지지 않게 전역 배율 1.5·2.0 으로 키움

○ 증강: 광도 증강 범위는 90 장에서 관측한 밝기 흩어짐에 맞추고, 기하 증강의 여백은 손실에서 뺌

○ 밝기 — 3 점 기준점 정규화

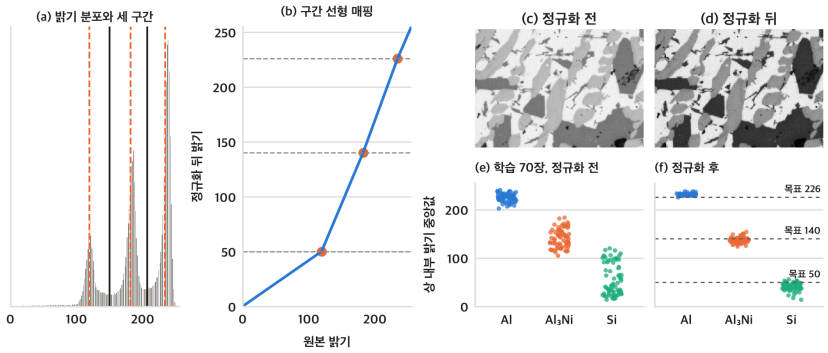


그림 4. 3 점 기준점 정규화의 절차와 효과.

학습 70 장 가운데 Si 내부 밝기가 가장 밝은 이미지(A130_step1_sample1)를 예로 (a) 밝기 분포를 Multi-Otsu로 세 구간으로 나누고(실선: 구간 경계, 점선: 구간 평균) (b) 세 평균을 50·140·226 으로 보내는 구간 선형 곡선으로 모든 픽셀을 옮긴다. (c)(d)는 같은 영역의 정규화 전후, (e)(f)는 학습 70 장의 상 내부 밝기 중앙값(이미지당 한 점)이며 정규화 뒤 세 상이 각자의 띠로 모인다. 정규화에는 정답 마스크를 쓰지 않는다.

- 이미지를 Multi-Otsu(밝기 분포를 자동으로 여러 구간으로 나누는 방법)[7, 8]로 어두운·중간·밝은 세 구간으로 나누고, 구간 평균을 Si·Al_3 Ni·α-Al 기준점으로 삼아 50·140·226 에 구간 선형(세 기준점 사이를 직선으로 이음)으로 맞춤
- 감마(중간 밝기만 바꾸는 비선형 차이)가 섞이면 양 끝 두 점만으로는 가운데 Al_3 Ni가 어긋나 3 점을 씀(그림 4 (b)). 중간 기준점을 빼고 2 점만 맞추면 교차검증 mIoU가 0.32 점 낮아졌음(배율 1.5 단일 모델). 중간 구간이 양쪽과 충분히 떨어지지 않으면(상대 분리 거리 min(중간−어두운, 밝은−중간) ÷ (밝은−어두운)이 0.15 미만) 두 점만 맞추며, 모든 계산이 이미지 안에서 끝나 정답 없는 평가 이미지에도 같은 절차를 씀

○ **크기 — 두께 기준 크기 보정**

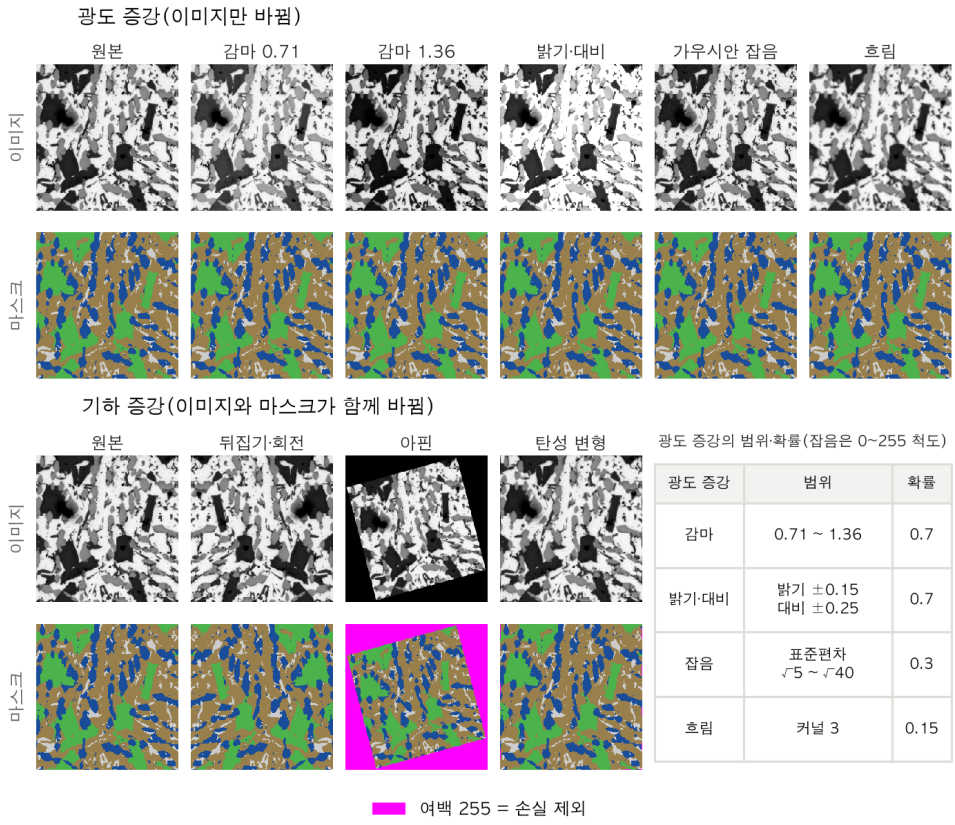
- 각 폭의 계수는 1440px의 두께 기준값 24.2px를 그 폭의 기준값으로 나눈 값이고(1440px = 1.0, 표 2), 이미지를 이 계수만큼 키운 뒤 전역 배율 1.5 또는 2.0 을 곱함

표 2. 이미지 폭별 크기 보정 계수

이미지 폭	675px	1096px	1230px	1278px	1440px
보정 계수	2.14	1.73	1.59	1.51	1.00

전역 배율은 크기 그룹 사이의 비는 두고 해상도만 올린다. 폭 2~6px인 가는 Eutectic Si 영역이 신경망의 해상도 축소 과정에서 사라지지 않게 배율 1.5 와 2.0 모델을 따로 학습해 앙상블(예측 확률 평균)했다.

○ **증강**



광도 증강의 범위·확률(잡음은 0~255 척도)

광도 증강	범위	확률
감마	0.71 ~ 1.36	0.7
밝기·대비	밝기 ±0.15 대비 ±0.25	0.7
잡음	표준편차 √5 ~ √40	0.3
흐림	커널 3	0.15

그림 5. 학습 때 거는 증강의 예.

학습 이미지(A15_step1_sample1) 타일에 광도 증강(위 두 줄)과 기하 증강(아래 두 줄)을 범위의 끝값으로 걸었다. 기하 증강이 만든 여백은 마스크에서 255(자홍)로 칠해 손실에서 뺀다. 오른쪽 아래 표는 광도 증강의 범위와 확률이다.

증강은 학습 때 이미지를 무작위로 바꿔 모델이 여러 변형을 보게 하는 것이다[9].

- 광도 증강(이미지에만 적용): 감마 범위 0.71~1.36 은 90 장의 상대 밝기 위치 (Al_3 Ni−Si)÷(α−Al−Si)가 5~95 백분위 구간 0.39~0.61 로 흩어진 것을 r = 0.5^γ로 환산해 정함(그림 5 오른쪽 아래 표)
- 기하 증강(이미지와 마스크에 똑같이 적용): 뒤집기·90 도 회전(각 확률 0.5), 아핀(확대 0.8~1.25, 회전 ±15 도, 0.5), 탄성 변형(고무판처럼 국소적으로 휘는 변환, 0.2)[10]

2-2. 전처리 절차

○ 광도 증강 → 정규화 → 크기 보정 → 타일·기하 증강 순서이며(표 3), 한 요소씩 빼면 크기 보정 1.04·정규화 0.68 점 mIoU가 낮아짐(배율 1.5 단일 모델, 다섯 fold 모두 하락)

표 3. 전처리 순서

원본 회색조 이미지
↓
(학습 때만) 광도 증강 — 감마·밝기·대비·잡음·흐림
↓
3 점 기준점 정규화 — 세 밝기 구간 평균 → 50 · 140 · 226 (중간 구간이 없으면 2 점)
↓
두께 기준 크기 보정 — 폭별 계수 × 전역 배율 (마스크 최근접, 회색조 선형 보간)
↓
무작위 타일 + 기하 증강 — 여백은 마스크 255
↓
모델 입력 — 1 채널, 0~1 범위

광도 증강(밝기·대비·감마를 무작위로 바꾸는 증강)은 정규화보다 먼저 건다. 그래야 증강으로 만든 밝기 차이가, 실제 추론 때 새 이미지가 거치는 것과 같은 정규화를 거친 뒤 모델에 들어간다. 크기를 바꿀 때 회색조 이미지는 이웃 픽셀 값을 섞는 선형 보간을, 정답 마스크는 가장 가까운 픽셀 값을 그대로 가져오는 최근접 보간을 쓴다. 마스크 값은 클래스 번호라 섞으면 1 과 3 사이에 없는 2 가 생기기 때문이다. 회전·아핀이 만든 빈 자리는 0(α-Al)으로 채우면 가짜 정답이 되므로 마스크에서 255 로 칠해 손실 함수 계산에서 뺀다(그림 5).

③ 모델링

3-1. 배경/알고리즘 소개

○ 3 클래스 분할 모델 두 개가 픽셀을 3 상으로 나누고, Si 분류기가 Si connected component마다 Primary/Eutectic을 정함

○ 두께 공식보다 높아진 점수는 형태가 아니라 보조 모델의 Primary Si 확률에서 나옴

○ 4 클래스를 한 번에 풀지 않는다

①장의 두 분석이 문제를 두 파트로 나눈다. 경계는 그 자리 주변 몇 픽셀만 보면 그을 수 있어, 3 클래스 분할 모델이 모든 픽셀을 α-Al/Al_3 Ni/Si로 나눈다. 같은 물질이라 밝기가 겹치는 Primary Si와 Eutectic Si는 덩어리 전체의 크기와 모양을 봐야 구분할 수 있는데, 픽셀 주변 일부만 보는 신경망은 큰 덩어리의 모양을 놓치기 쉽다. 그래서 Si는 덩어리(connected component) 단위로 Si 분류기가 Primary/Eutectic을 정한다(그림 6 (a)). 이렇게 나누면 점수가 떨어진 원인도 분할 오류와 분류 오류로 나눠 볼 수 있다(③-3).

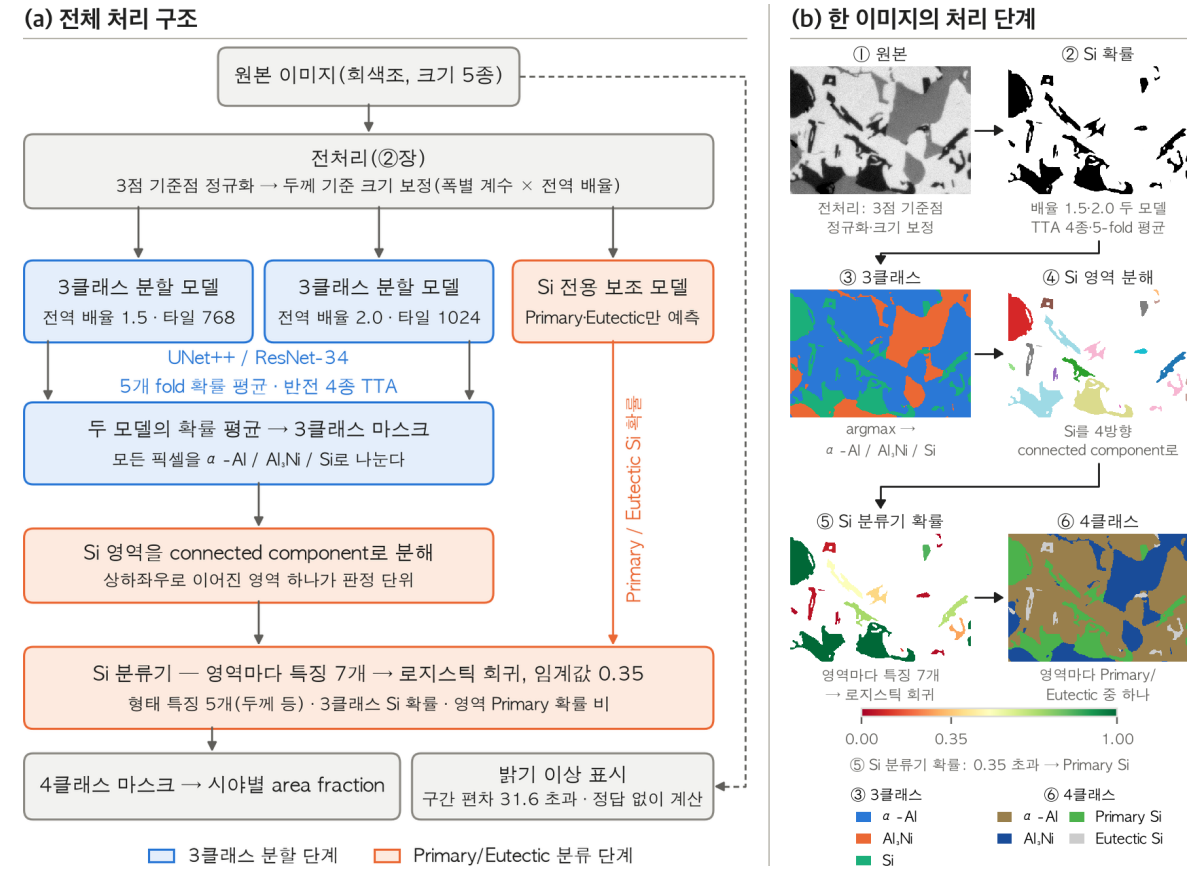


그림 6. 전체 처리 구조와 한 이미지의 처리 단계.

(a) 파랑은 3 클래스 분할 단계, 주황은 Primary/Eutectic 분류 단계다. 맨 아래 회색 두 상자(area fraction, 밝기 이상 표시)는 저장된 마스크와 원본으로 따로 계산하는 분석 단계이며 제출 코드에는 없다. 밝기 이상 표시는 구간 편차(Multi-Otsu 세 밝기 구간마다 평균과 최빈값의 절대 차이 중 가장 큰 값)가 검증 20 장에서 정한 31.6 을 넘는 이미지에 붙이는 참고 표시이며 예측에는 쓰지 않는다. TTA는 원본·좌우·상하 반전·180 도 회전으로 예측해 되돌려 평균하는 방법이다. (b) (a)의 과정을 실제 이미지로 나타냈다(검증 20 장 가운데 점수가 중간인 A186_step2_sample2 의 가운데 영역, 마지막 결과는 제출 예측과 사실상 같다(다른 픽셀 0.001% 미만)).

○ 나눠 푸는 이유와 Si 분류기의 입력(그림 7)

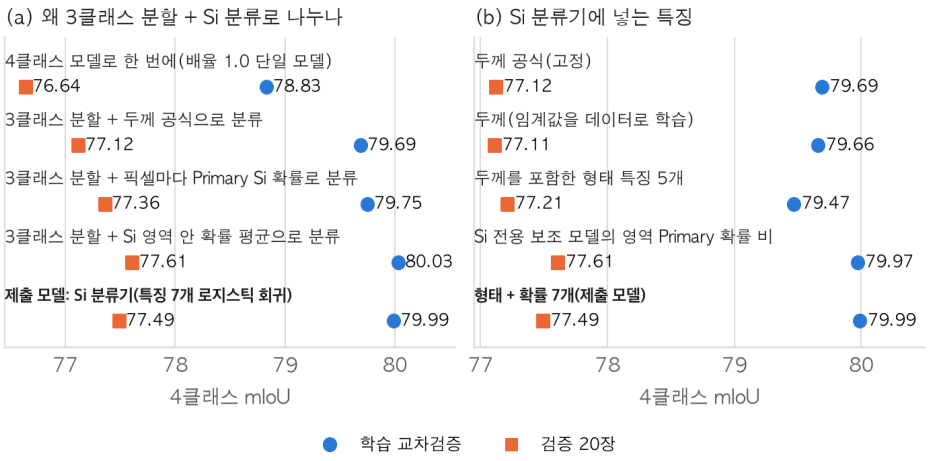


그림 7. 나눠 푸는 이유와 Si 분류기의 입력.

(a) 4 클래스를 한 번에 푼 모델(배율 1.0 단일 모델)과, 같은 3 클래스 분할(배율 1.5·2.0 앙상블, halo 재판정 끔. halo는 밝은 상과 어두운 상 사이에 생기는 가짜 중간 밝기 테두리) 위에서 Si를 따로 분류한 방식들이다. (b) 같은 분할에서 Si 분류기에 넣는 특징만 바꿨다. 모두 공식 산식이다.

(a) 나눠 푸는 이유: 4 클래스를 한 번에 푼 모델(78.83)보다 3 클래스로 나눈 뒤 Si를 따로 분류한 방식이 모두 높았다(79.69~80.03, 학습 교차검증). 다만 4 클래스 모델은 배율 1.0 단일 모델이라 해상도 차이가 함께 섞여 있다. 같은 3 클래스 분할 위에서는 두께 공식 79.69, 픽셀마다 보조 모델 확률 79.75, 덩어리 안 확률 평균 80.03 순으로 높아, 픽셀이 아니라 덩어리(connected component) 단위로 정하는 쪽이 나았다(검증 20 장도 77.12 < 77.36 < 77.61). 보조 모델은 Si 픽셀이 Primary Si와 Eutectic Si 가운데 어느 쪽인지 확률만 내는 Si 전용 신경망이다.

(b) Si 분류기의 입력: 형태 특징 다섯 개만 넣으면 79.47 로 두께 공식(79.69)보다 낮고, 영역 Primary 확률 비 하나만 넣어도 79.97 로 형태와 확률 7 개를 모두 넣은 제출 모델(79.99)과 거의 같았다. 이득은 보조 모델 확률에서 나오고 형태 특징은 거의 보태지 않는다. 제출 모델의 7 개 구성은 교차검증으로 먼저 골랐고 영역 확률 규칙(80.03)은 그 뒤에 찾았으므로, 결과를 보고 바꾸면 생기는 선택 편향을 피하려고 그대로 썼다.

3-2. 모델링 방법

○ 합금 ID로 묶은 그룹 5-fold 교차검증으로 설정을 골랐고, 입력 배율 1.5·2.0 두 모델을 앙상블함

○ 최종 구성은 UNet++/ResNet-34 3 클래스 분할 모델 두 개, Si 전용 보조 모델, Si 분류기(로지스틱 회귀)임(표 4)

○ 합금 그룹 5-fold 교차검증(Group K-Fold)을 썼다

같은 합금의 다른 시편이 학습과 평가에 함께 들어가면 미세조직이 닮아 점수가 부풀려지므로, 파일명의 합금 ID(①-2)로 묶어 5 개 fold로 나눴다(한 fold씩 번갈아 평가에 두고 나머지 넷으로 학습)(scikit-learn[5]의 StratifiedGroupKFold, fold마다 step 비율을 맞춤).

○ 데이터 사용 범위

- 모델 가중치는 학습 70 장으로만 학습했고(주최 측 답변[1]), 두께 기준 k·크기 보정 계수·정규화 목표값·증강 범위는 학습·검증 90 장의 정답 통계로 정함.

○ 최종 구성과 선택 근거

표 4 는 최종 구성의 항목마다 비교한 대안과 점수다. 점수는 학습 70 장 교차검증 mIoU(따로 적지 않으면 4 클래스)이고, 행마다 그때의 기준 구성에서 그 요소만 바꿔 쟀으므로 측정 조건이 다른 행끼리는 비교하지 않는다. '산식 확정 전 값'은 정답·예측 모두 없는 클래스를 평균에서 뺀 옛 산식으로 잰 값이다.

표 4. 최종 구성과 선택 근거

단계	항목	최종 선택	비교한 대안	측정 조건
3 상 분할 모델	구조	UNet++[12] 79.1	UNet[18] 78.6 · FPN(특징 피라미드 구조)[19] 75.7	초기 비교†
	인코더 초기값	ResNet-34[13], ImageNet[14] 사전학습 82.8	무작위 초기화 82.4 · MicroNet(현미경 사진 사전학습) 82.4 · 자기지도(가려진 패치 복원) 사전학습 82.6	인코더 비교(타일 512·20 에폭, 3 클래스 점수, 산식 확정 전 값)
	손실 함수	Lovász[11] 78.9	CE 78.8 · CE+Dice 78.9 · CE+Si 내부 가중 78.7	초기 비교†
	타일	768 → 79.1	256 → 78.4 · 512 → 78.9	
	입력 해상도	전역 배율 1.5(타일 768)와 2.0(타일 1024) 두 모델 앙상블 79.94	1.5 만 79.68 · 2.0 만 79.91	두께 공식·halo 끔, 산식 확정 전 값

	에폭	15	20: 3 클래스 +0.18, 4 클래스 +0.08(잡음 수준)	산식 확정 전 값
Primary/Eutectic 분류	분류 방법	Si 분류기 79.99: connected component마다 형태 5 개(폭 대비 두께·로그 면적·길쭉함·두께 편차·둘레 비)와 확률 2 개(3 클래스 Si 확률·영역 Primary 확률 비)를 넣은 로지스틱 회귀(L2 규제, 임계값 0.35)	두께 공식 79.69 · 픽셀 단위 확률 79.75 · 영역 확률 규칙 80.03(Si 분류기를 고른 뒤 찾은 규칙, 그림 7)	최종 구성, 공식 산식(임계값 0.35 는 산식 확정 전 산식으로 고름)
	보조 모델	Si 전용(출력 2 클래스) 79.99	4 클래스 보조 모델 79.89 · Si 전용(출력 4 클래스) 79.90(검증 20 장에서는 4 클래스 보조 모델이 0.43 높음)	최종 구성, 공식 산식

*CE는 교차 엔트로피(표준 분류 손실), Dice는 예측과 정답의 겹침 비율을 키우는 손실**[17]**, Lovász는 IoU를 근사해 최적화하는 손실**[11]**, Si 내부 가중은 Si 내부 픽셀 손실에 가중 2 를 준 것이다. UNet++**[12]**는 U자형 분할 구조 U-Net**[18]**의 개량판, 로지스틱 회귀는 특징의 가중합을 확률로 바꾸는 선형 분류기다. 구현은 PyTorch**[15]**·segmentation-models-pytorch**[16]**이다. †초기 비교: 두께 공식·halo 켬, 산식 확정 전 값. 비교하지 않은 고정값: 학습은 AdamW**[20]**(신경망 가중치를 고치는 최적화 방법, 학습률 3e-4), 이미지당 타일 8 장, 시드 42 이고, 체크포인트는 15 에폭 가운데 fold마다 검증 mIoU 점수가 가장 높은 에폭이며(교차검증 점수가 조금 낙관적일 수 있으나 검증 20 장·평가 10 장 점수와는 무관), 제출은 halo 재판정을 쓰지 않고, 추론은 반전 4 종 TTA(원본·좌우·상하 반전·180 도 회전으로 예측해 되돌려 평균)와 5 개 fold 확률 평균 뒤 원본 해상도로 복원한다.*

3-3. 성능

○ 검증 20 장 4 클래스 mIoU 77.49(겹치는 합금 7 장 78.74, 처음 보는 합금 13 장 76.82)임
○ 점수를 가장 많이 깎는 것은 3 클래스 분할 단계의 Al_3Ni↔Eutectic Si 혼동임

○ **검증 20 장의 4 클래스 mIoU는 77.49 다**

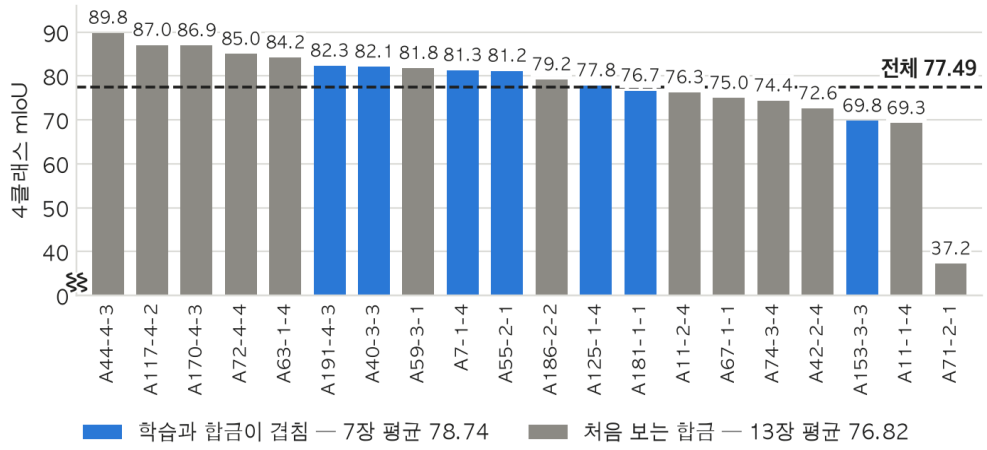


그림 8. 검증 20 장의 이미지별 4 클래스 mIoU(공식 산식).

학습 데이터와 합금이 겹치는 7 장과 처음 보는 합금 13 장을 색으로 나눴고, 점선은 전체 평균이다. 막대 아래 표시는 합금 ID-step-sample이다(예: A44-4-3 = A44_step4_sample3). 가장 낮은 A71-2-1(37.2)은 그림 9 에서 다룬다.

- 학습 70 장으로 학습한 모델로 검증 20 장 전부를 예측해 이미지별 mIoU를 평균했고(양식의 '데이터 개수(10)'는 평가 10 장 기준이라 검증은 20 장으로 평균함)(같은 구성의 학습 70 장 교차검증은 79.99), 평가 10 장 가운데 7 장이 학습 70 장 기준으로 처음 보는 합금이라(검증과만 겹치는 1 장 포함, ①-2) 겹침 여부로 나눠 보고함(겹치는 합금 7 장 78.74, 처음 보는 합금 13 장 76.82, 그림 8)

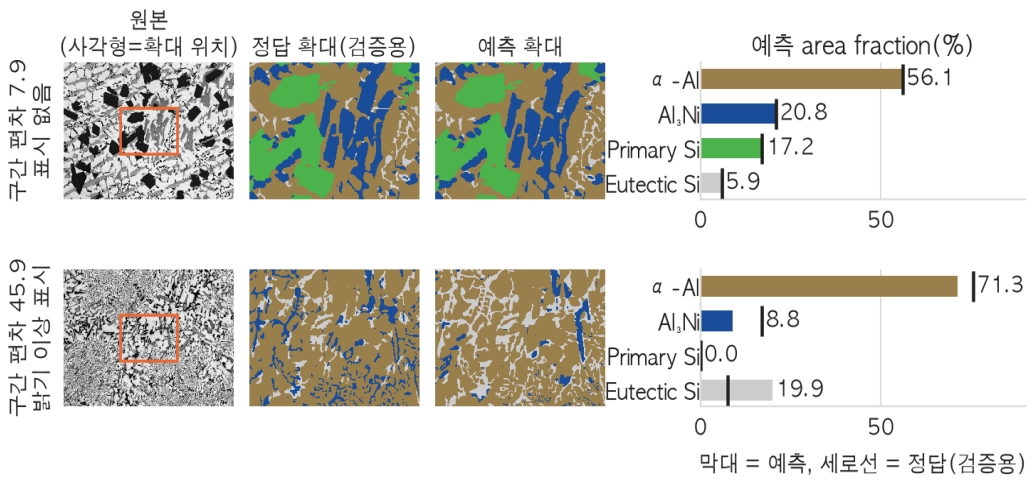


그림 9. 검증 20 장에서 점수가 가장 높은 이미지와 가장 낮은 이미지의 예측과 상 분율.

위는 점수가 가장 높은 이미지(mIoU 89.8), 아래는 가장 낮은 이미지(37.2)다. 정답과 예측은 원본의 주황 사각형 영역을 확대했다(픽셀 기준, 축척 없음). 막대는 예측 area fraction, 세로선은 검증용 정답이다. 아래 이미지는 구간 편차 45.9 로 밝기 이상 표시가 붙는다. Al_3Ni가 정규화 뒤에도 밝기 103 으로 학습 범위(124~154)보다 어두워 파란 침상 미세조직의 65%를 Eutectic Si(회색)로 예측했고, 분율 오차가 12.40%p였다.

○ 어디서 점수를 잃는가(그림 10)

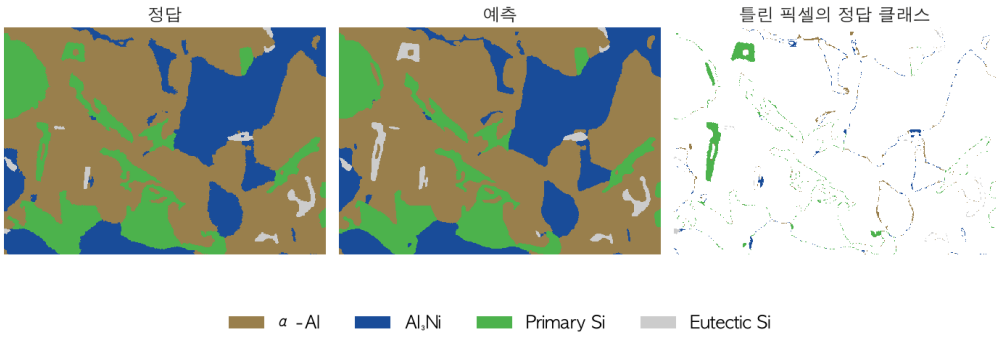


그림 10. 예측이 정답과 다른 픽셀의 위치.

그림 6 (b)와 같은 검증 이미지(A186_step2_sample2)의 가운데 영역이며, 틀린 픽셀을 정답 클래스 색으로 칠했다. 표 5 의 수치는 학습 70 장 교차검증에서 잰 것이라 이 한 장과 직접 대응하지는 않는다.

표 5. 두 병목의 오차 분해(제출 모델, 학습 70 장 교차검증 예측)

	Al_3Ni	Eutectic Si
경계 1px 이내가 오차(거짓 양성 + 거짓 음성 픽셀)에서 차지하는 비중	63.3%	50.1%
경계 1px를 채점에서 빼면 IoU	80.90 → 89.03	59.13 → 62.20
정답 connected component를 통째로 놓친 비율(개수 기준)	18.0%	20.6%
같은 것을 정답 픽셀 기준으로 보면	**1.1%**	**8.7%**

○ 두 병목은 성격이 다르다

- 표 5 에서 Al_3Ni는 오차가 경계에 몰리고 통째로 놓친 영역이 작아 경계 정밀도의 문제이고, Eutectic Si는 경계를 빼도 IoU가 크게 오르지 않고 통째로 놓친 영역이 많아 폭 2~6px의 가는 영역을 검출하는 것 자체가 문제임
- 제출 모델의 교차검증 예측에서 클래스 두 개 사이 혼동만 고쳤다고 가정한 점수 상승(쌍마다 따로 잰 상한)은 Al_3Ni↔Eutectic Si가 +6.36 점으로 가장 크고(Eutectic Si 오차 픽셀의 50.3%), 이 혼동은 3 클래스 분할 단계에서 생겨 Si 분류기로는 고치지 못함

○ **평가 10 장 마스킹**

- 같은 모델로 평가 10 장을 예측해 원본 해상도, 대회 지정 4 색, 정답과 같은 RGBA 형식, 파일명 규칙으로 저장함
- 열 장 모두 해상도·형식·색·파일명을 전수 검사했고, 제출 폴더만으로 다시 추론해 모든 픽셀이 제출본과 같음을 확인함. 예측 분율은 네 클래스 모두 학습·검증 정답의 범위 안에 있음(그림 11)

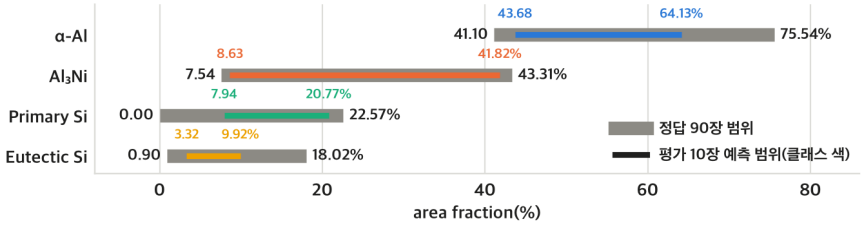


그림 11. 평가 10 장의 예측 area fraction 범위.

색은 평가 10 장 예측, 회색은 학습·검증 90 장 정답의 범위다. 네 클래스 모두 예측이 정답 범위 안에 든다.

3-4. 활용과 추가 연구

○ 같은 합금계의 탄성률 연구는 OM 분할을 계산 분율의 검증에만 썼고, 형태 정보를 OM 입력으로 더하는 것은 후속 과제로 남김

○ 이 모델은 같은 4 클래스 분할을 자동으로 하며(분율 평균 절대 오차 2%p 미만), 그 분율·형태 지표를 탄성률 예측에 더해 보는 것이 후속 연구임

○ **고탄성 합금 연구에서 OM 분할이 맡는 자리**

- 탄성률을 올리는 강화상은 Si와 Al_3Ni임. 같은 합금계를 다룬 Oh 외(2026)[21]는 XRD와 화학 조성으로 탄성률을, XRD만으로 상 부피분율을 예측했는데, 상 부피분율의 정답은 열역학 계산(FactSage)으로 만들고 864 개 시편의 OM 분할로 그 계산값을 검증했을 뿐 OM 분할을 예측 입력으로 쓰지는 않음(평균 절대 편차 Al 3.64, Si 2.91, Al_3Ni 4.30%)
- 같은 논문은 주조재처럼 집합조직이 약한 시편에서는 XRD가 침상의 길이·두께·연결성 같은 3 차원 형태를 거의 담지 못한다며 OM·SEM 이미지 같은 미세조직 입력을 더하는 것을 후속 과제로 제시함. 또 XRD는 결정 구조로 상을 가르는데 Primary Si와 Eutectic Si는 결정 구조가 같은 Si라 구분하지 못하고(그 논문도 분율을 Si 한 상으로 예측함), 둘의 구분은 모양을 보는 이미지 분할이 맡아야 함

○ **이 모델이 내놓는 것**

- 제출 코드는 이미지마다 4 클래스 마스크를 저장함. 그림 9 처럼 시야 한 장의 상 분율과 밝기 이상 표시는 저장된 마스크와 원본에서 따로 계산하며, 같은 계산을 추론 뒤에 붙일 수 있음
- 예측 분율의 평균 절대 오차는 α-Al 1.61·Al_3Ni 1.96·Primary Si 0.58·Eutectic Si 1.62%p이고, 이미지·클래스별 최대는 12.40%p임(검증 20 장, 정답 마스크 대비)
- 형태 지표의 예로, Eutectic Si 영역의 중심선을 따라 잰 폭의 평균(①장의 최대 내접원 두께와 다른 지표)으로 검증 20 장을 가는 순서대로 줄 세우면, 예측 마스크와 정답 마스크의 순서가 거의 같았음(Spearman 순위 상관 0.943, 1 이면 완전히 같음, SciPy[4]). 어느 사진의 Eutectic Si가 더 미세한지 비교할 수 있다는 뜻이며, μm 단위의 실제 폭은 아님

○ **후속 연구**

- 같은 시편의 XRD·탄성률 측정값과 짝지어, 이 모델에서 뽑은 분율·형태 지표를 추가 입력 후보로 써서 탄성률 예측이 나아지는지 검증할 수 있음
- step·합금 ID를 실제 조성·공정 기록과 대조하면 조건에 따른 상 분율 변화를 그릴 수 있어, 조성·공정에서 상 분율을 거쳐 탄성률로 이어지는 관계를 OM 쪽에서도 따라갈 수 있음

참고문헌

[1] KoMaP 주최 측. (2026). 멘토링 질의에 대한 답변(평가 지표 산식, 학습 데이터 범위 등). 2026-09-29 수신, 비공개.

[2] Lee, Y.-H., Kayani, S. H., Lee, J.-M., Lee, S.-I., Kim, S.-J., Jang, J.-I., & Cho, Y.-H. (2024). Microstructural refinement in a high elastic modulus Al-18Si-8Ni casting alloy. Journal of Alloys and Compounds, 1008, 176580. https://doi.org/10.1016/j.jallcom.2024.176580

[3] van der Walt, S., Schönberger, J. L., Nunez-Iglesias, J., Boulogne, F., Warner, J. D., Yager, N., Gouillart, E., Yu, T., & the scikit-image contributors. (2014). scikit-image: Image processing in Python. PeerJ, 2, e453. https://doi.org/10.7717/peerj.453

[4] Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

[5] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[6] KoMaP. (2026). 2026 KoMaP 경진대회 과제·데이터 안내(고탄성 알루미늄 합금 이미지 상분할). https://komap.ai/front/competition2026/process1 (2026-09-24 확인)

[7] Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66. https://doi.org/10.1109/TSMC.1979.4310076

[8] Liao, P.-S., Chen, T.-S., & Chung, P.-C. (2001). A fast algorithm for multilevel thresholding. Journal of Information Science and Engineering, 17(5), 713–727. https://doi.org/10.6688/JISE.2001.17.5.1

[9] Buslaev, A., Iglovikov, V. I., Khvedchenya, E., Parinov, A., Druzhinin, M., & Kalinin, A. A. (2020). Albumentations: Fast and flexible image augmentations. Information, 11(2), 125. https://doi.org/10.3390/info11020125

[10] Simard, P. Y., Steinkraus, D., & Platt, J. C. (2003). Best practices for convolutional neural networks applied to visual document analysis. Proceedings of the Seventh International Conference on Document Analysis and Recognition (ICDAR), 958–963. https://doi.org/10.1109/ICDAR.2003.1227801

[11] Berman, M., Triki, A. R., & Blaschko, M. B. (2018). The Lovász-Softmax loss: A tractable surrogate for the optimization of the intersection-over-union measure in neural networks. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 4413–4421. https://doi.org/10.1109/CVPR.2018.00464

[12] Zhou, Z., Rahman Siddiquee, M. M., Tajbakhsh, N., & Liang, J. (2018). UNet++: A nested U-Net architecture for medical image segmentation. Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA 2018), Lecture Notes in Computer Science, 11045, 3–11. https://doi.org/10.1007/978-3-030-00889-5_1

[13] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–

778. https://doi.org/10.1109/CVPR.2016.90

[14] Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., & Fei-Fei, L. (2009). ImageNet: A large-scale hierarchical image database. 2009 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 248–255. https://doi.org/10.1109/CVPR.2009.5206848

[15] Paszke, A., Gross, S., Massa, F., Lerer, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems 32 (NeurIPS 2019). arXiv:1912.01703

[16] Iakubovskii, P. (2019). Segmentation Models Pytorch. GitHub repository. https://github.com/qubvel/segmentation_models.pytorch

[17] Milletari, F., Navab, N., & Ahmadi, S.-A. (2016). V-Net: Fully convolutional neural networks for volumetric medical image segmentation. 2016 Fourth International Conference on 3D Vision (3DV), 565–571. https://doi.org/10.1109/3DV.2016.79

[18] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015), Lecture Notes in Computer Science, 9351, 234–241. https://doi.org/10.1007/978-3-319-24574-4_28

[19] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 936–944. https://doi.org/10.1109/CVPR.2017.106

[20] Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. International Conference on Learning Representations (ICLR 2019). arXiv:1711.05101

[21] Oh, S., Jung, J., Choi, J., Lee, Y.-H., Cho, Y.-H., Oh, M., & Lee, H. W. (2026). Prediction of elastic modulus, Poisson's ratio, and phase volume fraction from XRD pattern in high-elasticity aluminum alloys for casting using deep learning. Journal of Alloys and Compounds, 1060, 187234. https://doi.org/10.1016/j.jallcom.2026.187234